Université Sultan Moulay Slimane
Faculté des Sciences et Techniques de Béni Mellal

Travaux pratiques – TP3

Analyse automatique des sentiments

Classification d'avis cinématographiques avec le dataset IMDB

Étudiant : Amin Joundi

Formation : Master AIDC

Établissement : FST Béni Mellal

Date : 19 octobre 2026

Année universitaire 2026–2027

Table des matières

1 Cadre et objectif du travail **2**

2 Données utilisées **2**
2.1 Description du corpus 2

3 Démarche expérimentale **2**
3.1 Préparation des avis 2
3.2 Représentation TF-IDF 3
3.3 Découpage et modèles 3
3.4 Mesures d'évaluation 3

4 Résultats et observations **3**
4.1 Comparaison des modèles 3
4.2 Analyse des erreurs 4

5 Discussion **4**
5.1 Points positifs 4
5.2 Limites identifiées 4

6 Conclusion **4**

A Extraits de code utilisés **5**
A.1 Vectorisation TF-IDF et préparation de la cible 5
A.2 Entraînement et évaluation 5

1 Cadre et objectif du travail

L'analyse de sentiments est une application du traitement automatique du langage naturel (NLP). Elle consiste à exploiter le contenu d'un texte afin d'en estimer la polarité, par exemple positive ou négative. Cette technique peut être utilisée pour étudier les avis de clients, analyser des commentaires en ligne ou résumer les réactions à un produit ou à un service.

Dans ce TP, l'objectif est de construire une chaîne de classification binaire capable d'attribuer une étiquette positive ou négative à un avis de film. Deux méthodes classiques d'apprentissage automatique sont comparées : la régression logistique et le classifieur Naïve Bayes multinomial. La représentation textuelle repose sur TF-IDF.

2 Données utilisées

2.1 Description du corpus

L'expérience utilise le *IMDB Dataset of 50K Movie Reviews*. Chaque ligne contient le texte d'un avis, stocké dans la colonne `review`, ainsi que son sentiment, enregistré dans la colonne `sentiment`. Les deux étiquettes possibles sont `positive` et `negative`.

Table 1 – Caractéristiques générales du corpus

Caractéristique	**Valeur**
Nombre d'avis	50 000
Avis positifs	25 000
Avis négatifs	25 000
Nombre de classes	2
Répartition des classes	50 % / 50 %
Longueur moyenne indiquée	Environ 230 mots

La répartition équilibrée des catégories est utile pour l'apprentissage : aucune classe n'est majoritaire. L'accuracy permet donc d'obtenir une première vue d'ensemble des prédictions, même si elle doit être complétée par d'autres mesures pour une évaluation plus détaillée.

3 Démarche expérimentale

3.1 Préparation des avis

Avant l'apprentissage, le texte doit être rendu plus exploitable. Le traitement décrit dans ce TP comprend les opérations suivantes :

— suppression des balises HTML présentes dans certains commentaires ;
— nettoyage de la ponctuation et des éléments non nécessaires ;
— suppression des mots-outils (*stopwords*) ;
— lemmatisation afin de ramener certains mots à leur forme de base.

Le prétraitement réduit une partie du bruit textuel. Il faut néanmoins garder à l'esprit qu'un nettoyage trop agressif peut supprimer des indices utiles au sentiment, notamment certains termes de négation.

3.2 Représentation TF-IDF

Les algorithmes classiques ne traitent pas directement un commentaire sous la forme d'une phrase. TF-IDF (*Term Frequency–Inverse Document Frequency*) convertit donc les textes en vecteurs numériques. Le poids d'un terme dépend de sa fréquence dans un document et de son caractère plus ou moins courant dans l'ensemble du corpus.

Dans la configuration présentée, le vocabulaire est limité à 5 000 caractéristiques. La matrice obtenue possède ainsi les dimensions

$$X \in R^{50000\times5000}.$$

Chaque ligne représente un avis et chaque colonne correspond à une caractéristique textuelle retenue par le vectoriseur.

3.3 Découpage et modèles

Le corpus est réparti entre un ensemble d'entraînement représentant 80 % des données et un ensemble de test représentant 20 %. Les modèles sont ajustés sur la partie d'entraînement puis évalués sur les 10 000 avis du test.

Les deux méthodes étudiées sont :

— **Régression logistique :** un classifieur linéaire qui estime la probabilité d'appartenance à une classe à partir des caractéristiques du texte ;

— **Naïve Bayes multinomial :** un modèle probabiliste souvent utilisé pour la classification de textes, reposant sur une hypothèse simplificatrice d'indépendance conditionnelle des caractéristiques.

3.4 Mesures d'évaluation

L'accuracy correspond à la proportion de prédictions correctes parmi l'ensemble des exemples évalués. Le rapport de classification présente également la précision, le rappel et le score F1 pour chaque classe. La matrice de confusion aide à distinguer les avis positifs et négatifs correctement classés des erreurs commises par le modèle.

4 Résultats et observations

4.1 Comparaison des modèles

Les accuracies rapportées pour l'ensemble de test sont présentées dans le tableau suivant.

Table 2 – Comparaison des résultats sur l'ensemble de test

Classifieur	Accuracy	Observation
Régression logistique	88,48 %	Meilleur résultat rapporté
Naïve Bayes multinomial	84,90 %	Résultat inférieur

La régression logistique obtient une accuracy supérieure de 3,58 points de pourcentage. Sur la base de cette mesure, elle constitue le meilleur des deux modèles testés dans cette expérience. Ce constat reste lié au corpus, au prétraitement et aux paramètres employés ; il ne signifie pas qu'elle sera nécessairement supérieure dans tous les contextes.

4.2 Analyse des erreurs

Le rapport de classification associé à la régression logistique indique des valeurs de précision et de rappel globalement proches de 0,88 pour les deux catégories, selon les résultats présentés dans le document de référence. La matrice de confusion permet d'examiner plus précisément les faux positifs et les faux négatifs.

Des essais sur des commentaires supplémentaires illustrent également le comportement du système. Les avis exprimant un sentiment fort sont plus faciles à interpréter que les avis ambigus. Par exemple, une formulation telle que *« It was okay, not great but not bad either »* exprime une opinion mitigée, mais le classifieur doit tout de même choisir entre les deux classes disponibles. Le modèle la classe comme négative dans le test rapporté.

5 Discussion

5.1 Points positifs

Cette expérience met en place les principales étapes d'un projet de classification de textes : préparation des données, transformation numérique, entraînement de plusieurs modèles et évaluation sur un jeu de test. TF-IDF fournit une représentation simple et efficace pour des classifieurs classiques. Dans les résultats rapportés, la régression logistique offre le meilleur compromis parmi les deux méthodes comparées.

5.2 Limites identifiées

La représentation TF-IDF décrit principalement la présence et le poids des termes ; elle ne modélise pas directement toute la structure d'une phrase. L'ordre des mots, les négations complexes, l'ironie et les nuances d'une opinion peuvent donc être difficiles à interpréter. De plus, une classification binaire ne permet pas de représenter explicitement une troisième catégorie neutre.

6 Conclusion

Ce TP porte sur la classification binaire de commentaires de films à partir du corpus IMDB. La chaîne étudiée associe le nettoyage du texte, la représentation TF-IDF limitée à 5 000 caractéristiques et l'entraînement de deux classifieurs. Les résultats rapportés sont de 88,48 % d'accuracy pour la régression logistique et de 84,90 % pour Naïve Bayes multinomial.

La comparaison favorise la régression logistique dans le cadre de cette expérience. Les tests montrent toutefois qu'une bonne performance globale ne suffit pas à résoudre toutes les difficultés du langage naturel, en particulier les avis ambigus ou nuancés. Des modèles contextuels et une analyse plus approfondie des erreurs pourraient améliorer les résultats.

A Extraits de code utilisés

Les extraits ci-dessous illustrent la vectorisation et l'entraînement des deux modèles. Ils reprennent les paramètres et les scores indiqués dans les résultats du TP. Pour une exécution complète, les variables `df`, `X_train`, `X_test`, `y_train` et `y_test` doivent avoir été préparées au préalable.

A.1 Vectorisation TF-IDF et préparation de la cible

```python
from sklearn.feature_extraction.text import TfidfVectorizer

vectorizer = TfidfVectorizer(max_features=5000)
X = vectorizer.fit_transform(df["cleaned_review"])

y = df["sentiment"].map({
    "positive": 1,
    "negative": 0
})

print(X.shape)  # attendu : (50000, 5000)
```

A.2 Entraînement et évaluation

```python
from sklearn.linear_model import LogisticRegression
from sklearn.naive_bayes import MultinomialNB
from sklearn.metrics import accuracy_score

# Regression logistique
model = LogisticRegression(max_iter=1000)
model.fit(X_train, y_train)
y_pred = model.predict(X_test)
print("Accuracy :", accuracy_score(y_test, y_pred))

# Naive Bayes multinomial
nb_model = MultinomialNB()
nb_model.fit(X_train, y_train)
y_pred_nb = nb_model.predict(X_test)
print("Accuracy :", accuracy_score(y_test, y_pred_nb))
```